

**Universidad Nacional Autónoma de
México**

Facultad de Ciencias

Inteligencia artificial

Proyecto 4

Hugo Alberto Gómez Gutiérrez

Humberto Salinas Hernandez

Nieves Moran Silva

Introducción

Hoy en día la tecnología más preciso la inteligencia artificial a llegado muy lejos, se podría decir que en algunos campos el avance es sorprendente y su uso es muy beneficioso para diferentes áreas.

Un ejemplo claro son las redes neuronales. Las redes neuronales tienen muchos usos pero en este caso concreto se utilizará en el reconocimiento de imágenes.

Teoría

Las redes neuronales convolucionales, en cuanto a el paradigma de la inteligencia artificial, son parte del paradigma que trata de actuar como los seres humanos. Consideramos que pertenece a este por que su funcionamiento trata de simular la del cerebro humano.

REAS

Actuadores: simplemente decidir si cierta imagen pertenece a una clase.

Sensores: imagenes.


Entorno: pues en realidad el entorno, los objetos con los que interactúa son únicamente imágenes.

Medida de rendimiento: que tantas imágenes puede clasificar correctamente.

¿Cómo funcionan las neuronas?

Las neuronas son los entes fundamentales de las redes neuronales. Estas funcionan como sigue:

Cada neurona tiene conectada a ella a otras neuronas y cada conexión tiene un peso específico. Ahora, las neuronas tienen asociada una función de activación que decide si la neurona se dispara o no dependiendo de los disparos de sus neuronas vecinas y su umbral de excitación.




neurona, con sus entradas, pesos y la salida.

Explicación de las redes neuronales simples.

En las redes neuronales clásicas las neuronas están divididas en capas divididas en tres categorías que son:

- Capa de entrada
- Capa oculta
- Capa de salida

Cada neurona en una capa está conectada con todas las neuronas de las capas vecinas.



Estructura de las redes neuronales convolucionales

Las redes neuronales convolucionales tienen 3 características que las distinguen de las redes neuronales clásicas:

- Especialización por regiones

- Agrupamiento (pooling)
- Pesos y umbrales compartidos

Primero la especialización por regiones se hace conectando áreas de una capa con una única neurona de la capa siguiente. Con esto se logra que la siguiente capa codifique la información de manera más abstracta ayudado del concepto de convolución que trataremos de dar una explicación más abajo.

Luego, mezcladas con las capas de convolución hay capas de agrupamiento. Las más populares son las de agrupamiento máximo y lo que hacen es, en esencia, ayudar a las capas convolucionales siguientes a trabajar sobre regiones más pequeñas. Es decir filtran todavía más la información de las capas anteriores. Esto es muy útil, en especial para el reconocimiento de imágenes, en cuanto a las transformaciones invariantes.

Por ejemplo : el reconocimiento de una imagen no debería depender de si esta está rotada o no. Y la última característica es que en las redes neuronales clásicas las neuronas en cada capa tienen sus propios pesos y umbrales. A diferencia de las redes convolucionales que los pesos y umbrales van a estar asignados por racimos de neuronas que como se dijo más arriba se especializan en ciertas regiones. Esto permite que la red neuronal sea más eficiente al trabajar con menos pesos.

Formalización de las redes neuronales.

En realidad las conexiones entre las capas se pueden describir fácilmente como una función de los pesos y umbrales de las áreas. Sin embargo para hacer esto se necesita una función llamada convolución cuya definición para una dimensión es la siguiente:

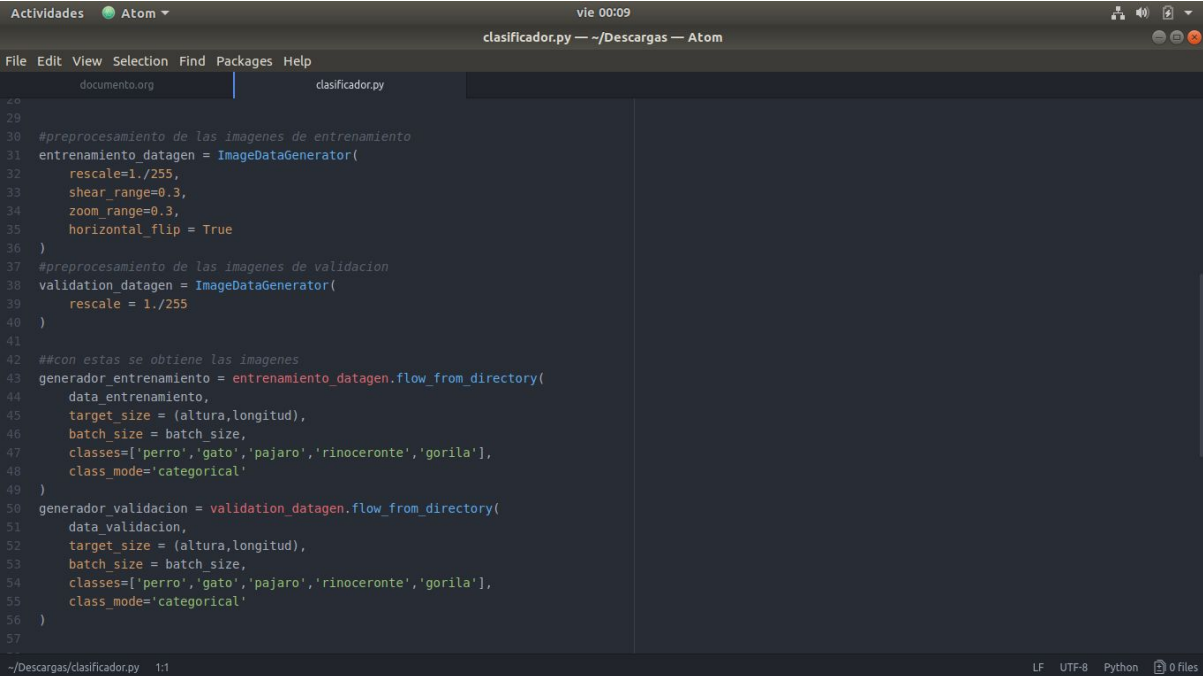
$$(f * g)(c) = \sum_a f(a) * g(c - a)$$

Por supuesto, esta definición puede y para las redes neuronales convolucionales, es generalizada a espacios vectoriales. Esta función en esencia la representa qué tanto cambia la forma de una función con respecto a otra. De esta forma las neuronas de las áreas de la capa antecesora son similar a una función de la región plasmando este "cambio de forma" en la neurona de la capa sucesora. La siguiente imagen pretende mostrarlo. La imagen representa lo que se hace con el procesamiento de

imágenes (donde las convoluciones también son ocupadas) y no precisamente con redes neuronales. Sin embargo es fácil imaginar que el kernel es la porción de neuronas destinadas a una región que sería el input y cuya salida es el punto rojo output.

ENTRENAMIENTO

Para entrenar una red neuronal se necesitan dos conjuntos de imágenes. Un tipo de imágenes para entrenamiento y un conjunto de imágenes para probar que tan bien la red neuronal ha aprendido. Al primer tipo le llamamos de entrenamiento y al segundo de validación. A continuación se muestra el código para cargar estos conjuntos de imágenes.

A screenshot of the Atom code editor interface. The window title is 'vie 00:09' and the file path is 'clasificador.py -- ~/Descargas -- Atom'. The menu bar includes 'File', 'Edit', 'View', 'Selection', 'Find', 'Packages', and 'Help'. The code is written in Python and defines two ImageDataGenerator objects for training and validation data. The training generator includes rescaling, shearing, zooming, and horizontal flipping. Both generators are configured to load data from a directory and use categorical classes for training. The code is as follows:

```
29
30 #preprocesamiento de las imagenes de entrenamiento
31 entrenamiento_datagen = ImageDataGenerator(
32     rescale=1./255,
33     shear_range=0.3,
34     zoom_range=0.3,
35     horizontal_flip = True
36 )
37 #preprocesamiento de las imagenes de validacion
38 validation_datagen = ImageDataGenerator(
39     rescale = 1./255
40 )
41
42 ##con estas se obtiene las imagenes
43 generador_entrenamiento = entrenamiento_datagen.flow_from_directory(
44     data_entrenamiento,
45     target_size = (altura,longitud),
46     batch_size = batch_size,
47     classes=['perro','gato','pajaro','rinoceronte','gorila'],
48     class_mode='categorical'
49 )
50 generador_validacion = validation_datagen.flow_from_directory(
51     data_validacion,
52     target_size = (altura,longitud),
53     batch_size = batch_size,
54     classes=['perro','gato','pajaro','rinoceronte','gorila'],
55     class_mode='categorical'
56 )
57
```

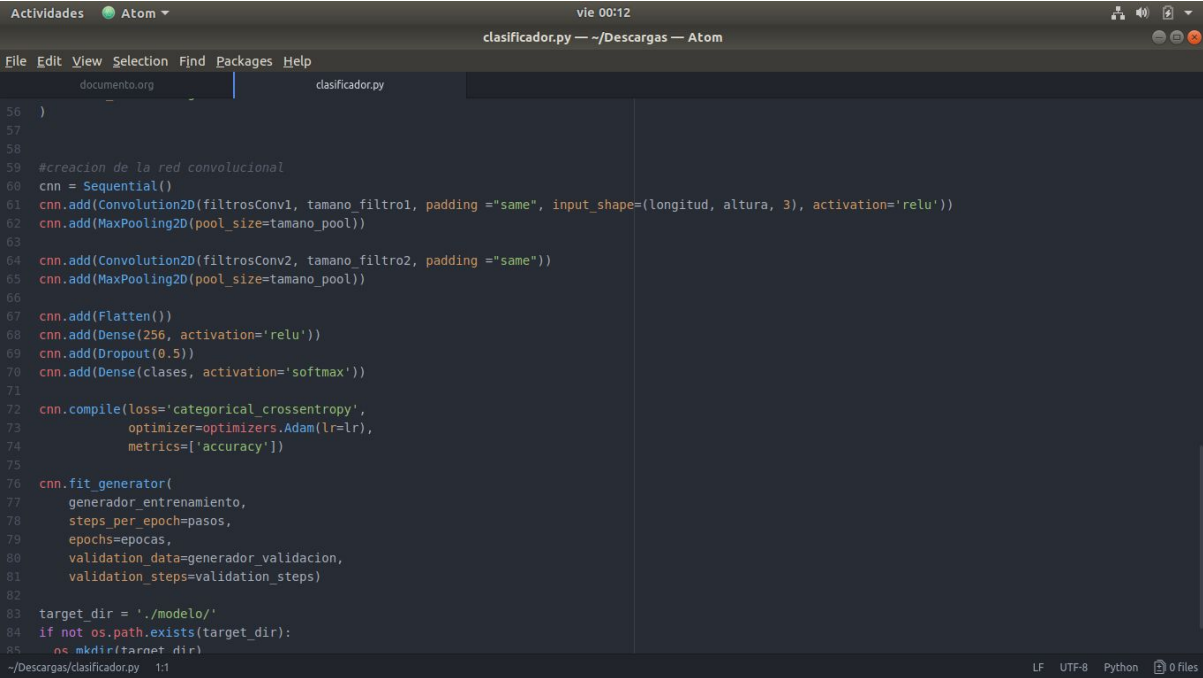
The status bar at the bottom shows the file path '~/Descargas/clasificador.py', line 1:1, and encoding 'UTF-8'.

la función ImageDataGenerator toma un conjunto de imágenes semilla y les aplica transformaciones creando conjuntos más grandes esto con el objetivo de que el aprendizaje se mas robusto.

Definición

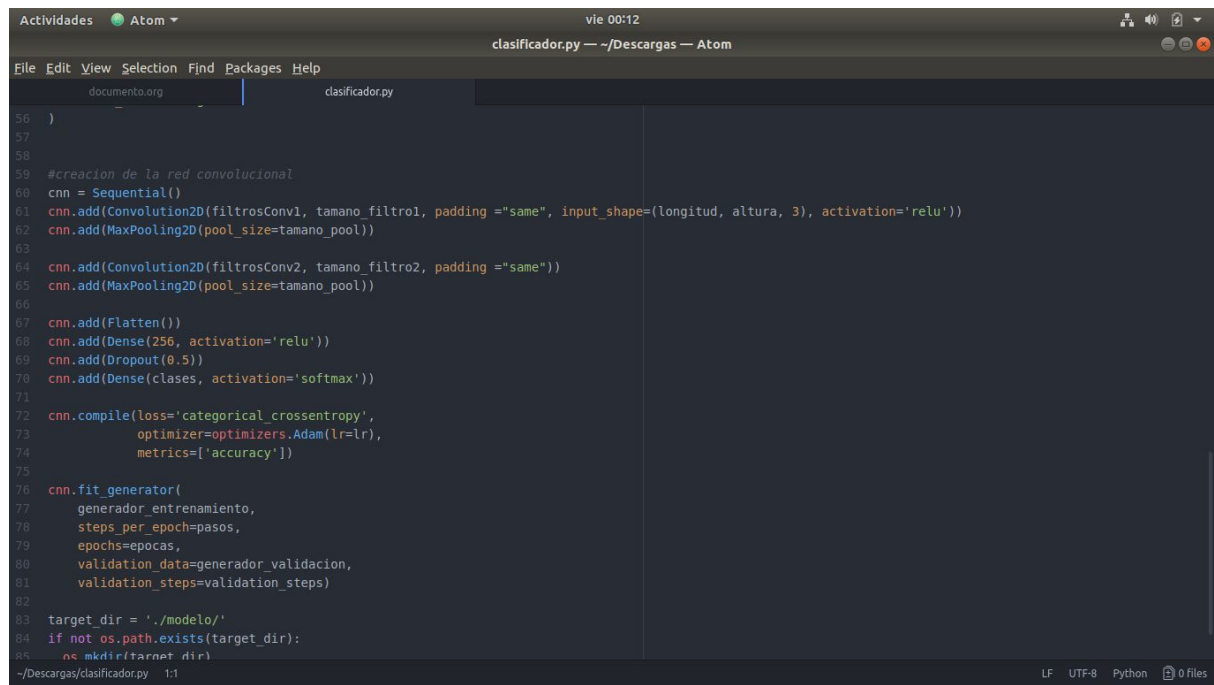
La función Sequential() establece que el modelo va a ser una red secuencial ósea en capas. Primero se agrega la capa que va a ser la de entrada.

Nota que esta va a ser la única capa que tiene el parámetro input_shape.



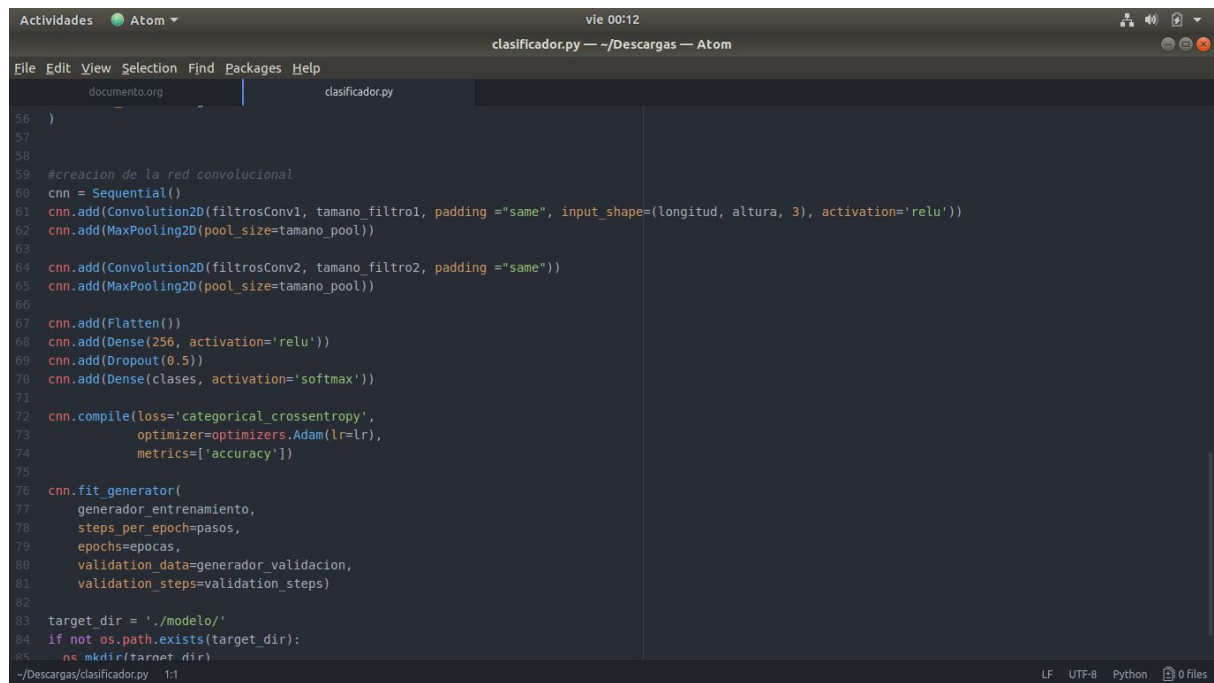
```
56 )
57
58
59 #creacion de la red convolucional
60 cnn = Sequential()
61 cnn.add(Convolution2D(filtrosConv1, tamano_filtro1, padding ="same", input_shape=(longitud, altura, 3), activation='relu'))
62 cnn.add(MaxPooling2D(pool_size=tamano_pool))
63
64 cnn.add(Convolution2D(filtrosConv2, tamano_filtro2, padding ="same"))
65 cnn.add(MaxPooling2D(pool_size=tamano_pool))
66
67 cnn.add(Flatten())
68 cnn.add(Dense(256, activation='relu'))
69 cnn.add(Dropout(0.5))
70 cnn.add(Dense(clases, activation='softmax'))
71
72 cnn.compile(loss='categorical_crossentropy',
73             optimizer=optimizers.Adam(lr=lr),
74             metrics=['accuracy'])
75
76 cnn.fit_generator(
77     generador_entrenamiento,
78     steps_per_epoch=pasos,
79     epochs=epocas,
80     validation_data=generador_validacion,
81     validation_steps=validation_steps)
82
83 target_dir = './modelo/'
84 if not os.path.exists(target_dir):
85     os.mkdir(target_dir)
```

Luego, como se explicamos anteriormente en las redes neuronales convolucionales las capas escondidas están combinadas entre capas convolucionales y capas de agrupamiento(pooling). Realmente los parámetros como los filtros y tamaños de estos, uno los determina por experimentación más que por razones lógicas ya que en realidad no se puede probar formalmente que ciertos parámetros vayan a funcionar, dada la naturaleza de las redes neuronales. Así que estos parámetros los pusimos porque nos funcionaron.



```
56 )
57
58
59 #creacion de la red convolucional
60 cnn = Sequential()
61 cnn.add(Convolution2D(filtrosConv1, tamano_filtro1, padding ="same", input_shape=(longitud, altura, 3), activation='relu'))
62 cnn.add(MaxPooling2D(pool_size=tamano_pool))
63
64 cnn.add(Convolution2D(filtrosConv2, tamano_filtro2, padding ="same"))
65 cnn.add(MaxPooling2D(pool_size=tamano_pool))
66
67 cnn.add(Flatten())
68 cnn.add(Dense(256, activation='relu'))
69 cnn.add(Dropout(0.5))
70 cnn.add(Dense(clases, activation='softmax'))
71
72 cnn.compile(loss='categorical_crossentropy',
73             optimizer=optimizers.Adam(lr=lr),
74             metrics=['accuracy'])
75
76 cnn.fit_generator(
77     generador_entrenamiento,
78     steps_per_epoch=pasos,
79     epochs=epocas,
80     validation_data=generador_validacion,
81     validation_steps=validation_steps)
82
83 target_dir = './modelo/'
84 if not os.path.exists(target_dir):
85     os.mkdir(target_dir)
```

Al final se agrega una capa que va a decir cuáles fueron los resultados de la predicción y es la capa de salida.



```
56 )
57
58
59 #creacion de la red convolucional
60 cnn = Sequential()
61 cnn.add(Convolution2D(filtrosConv1, tamano_filtro1, padding ="same", input_shape=(longitud, altura, 3), activation='relu'))
62 cnn.add(MaxPooling2D(pool_size=tamano_pool))
63
64 cnn.add(Convolution2D(filtrosConv2, tamano_filtro2, padding ="same"))
65 cnn.add(MaxPooling2D(pool_size=tamano_pool))
66
67 cnn.add(Flatten())
68 cnn.add(Dense(256, activation='relu'))
69 cnn.add(Dropout(0.5))
70 cnn.add(Dense(clases, activation='softmax'))
71
72 cnn.compile(loss='categorical_crossentropy',
73             optimizer=optimizers.Adam(lr=lr),
74             metrics=['accuracy'])
75
76 cnn.fit_generator(
77     generador_entrenamiento,
78     steps_per_epoch=pasos,
79     epochs=epocas,
80     validation_data=generador_validacion,
81     validation_steps=validation_steps)
82
83 target_dir = './modelo/'
84 if not os.path.exists(target_dir):
85     os.mkdir(target_dir)
```

Predicción

En la predicción ocupamos el archivo que se generan en el aprendizaje que nos proporciona los pesos.

Los pesos son coeficientes que pueden adaptarse dentro de la red que determinan la intensidad de la señal de entrada registrada por la neurona artificial. Ellos son la medida de la fuerza de una conexión de entrada. Estas fuerzas pueden ser modificadas en respuesta de los ejemplos de entrenamiento de acuerdo a la topología específica o debido a las reglas de entrenamiento.

Ventajas y desventajas

Una ventaja muy importante es que la red neuronal no procesa toda la imagen, ya que esta es procesada por partes, esto hace que las neuronas no incrementen de forma innecesaria.

Ventaja los usos de esta herramienta son ocupados en la vida cotidiana, es decir que aunque el entrenamiento es pesado, vale la pena el trabajo.

Una desventaja es que el entrenamiento llega a ser tardado.

Otra desventaja es la necesidad de buscar imágenes variadas de lo que deseamos entrenar, esto llega a ser tedioso ya que muchas veces no se cuenta con los recursos necesarios para el entrenamiento correcto.

Conclusión

Como se ha mencionado las redes neuronales pueden solucionar problemas que con los algoritmos tradicionales resultaría muy complicado por no decir imposible. Pero se debe de mencionar que un mal manejo en la etapa de entrenamiento puede resultar muy problemático también en un mal armado de la capa oculta puede llegar a ser ineficiente. Cabe mencionar que el proceso de entrenamiento puede llegar a ser tardado si no se cuenta con los recursos necesarios, por eso

Bibliografía

<https://colah.github.io/posts/2014-07-Conv-Nets-Modular/>

<https://www.youtube.com/watch?v=ns2L2T6wvAY>

https://es.wikipedia.org/wiki/Redes_neuronales_convolucionales

<https://relopezbriega.github.io/blog/2016/08/02/redes-neuronales-convolucionales-con-tensorflow/>